

Autor : Daniel Ivan Medina Barreras

[Datos \(https://github.com/noelDz/COVID19_Mx_opendata\)](https://github.com/noelDz/COVID19_Mx_opendata)

```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import scipy as sc

import plotly
import plotly.graph_objs as go
from plotly.offline import init_notebook_mode, iplot
import plotly.offline as py
import plotly.figure_factory as ff

import seaborn as sb

import pandas_profiling
```

```
In [2]: init_notebook_mode(connected=True)
```

```
In [3]: %matplotlib inline
```

Lectura de la fuente de información

```
In [4]: df = pd.read_csv('./data_COVID19Mx/Confirmados/COVID19Mx_confirmados28-03-20.csv', index_col=0)
```

Los metadatos de la fuente de información

```
In [5]: df.columns
```

```
Out[5]: Index(['index', 'NumCaso', 'Estado', 'Sexo', 'Edad',
              'Fecha_de_Inicio_de_Síntomas',
              'IdentificacionRT-PCR_COVID19(tiemporeal)', 'Procedencia',
              'Llegada_México'],
              dtype='object')
```

In [6]: `df.head()`

Out[6]:

	index	NumCaso	Estado	Sexo	Edad	Fecha_de_Inicio_de_Síntomas	IdentificacionRT-PCR_COVID19(tiemporeal)	Proceder
0	313	314	MÉXICO	M	44	2020-02-19	confirmado	I
1	5	6	MÉXICO	M	71	2020-02-21	confirmado	I
2	0	1	CDMX	M	35	2020-02-22	confirmado	I
3	1	2	SINALOA	M	41	2020-02-22	confirmado	I
4	2	3	CDMX	M	59	2020-02-23	confirmado	I

In [7]: `df.info()`

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 848 entries, 0 to 847
Data columns (total 9 columns):
index                    848 non-null int64
NumCaso                  848 non-null int64
Estado                   848 non-null object
Sexo                     848 non-null object
Edad                     848 non-null int64
Fecha_de_Inicio_de_Síntomas 848 non-null object
IdentificacionRT-PCR_COVID19(tiemporeal) 848 non-null object
Procedencia              848 non-null object
Llegada_México           567 non-null object
dtypes: int64(3), object(6)
memory usage: 66.2+ KB
```

In [8]: `DataFrameAnálisisEstadístico=df.describe()`

In [9]: `DataFrameAnálisisEstadístico`

Out[9]:

	index	NumCaso	Edad
count	848.000000	848.000000	848.000000
mean	423.500000	424.500000	42.443396
std	244.940809	244.940809	15.583014
min	0.000000	1.000000	0.000000
25%	211.750000	212.750000	30.000000
50%	423.500000	424.500000	41.000000
75%	635.250000	636.250000	53.000000
max	847.000000	848.000000	88.000000

In [10]: `d=ff.create_table(DataFrameAnálisisEstadístico)`

```
In [11]: iplot(d)
```

index	NumCaso	E
848.0	848.0	8
423.5	424.5	4
244.94080917642123	244.94080917642123	1
0.0	1.0	0
211.75	212.75	3

```
In [12]: pandas_profiling.ProfileReport(df)
```

```
/home/saxsa/anaconda3/lib/python3.7/site-packages/pandas_profiling/describe.py:  
392: FutureWarning:
```

```
The join_axes-keyword is deprecated. Use .reindex or .reindex_like on the resul  
t to achieve the same functionality.
```

Out[12]:

Overview

Dataset info

Number of variables	9
Number of observations	848
Total Missing (%)	3.7%
Total size in memory	66.2 KiB
Average record size in memory	80.0 B

Variables types

Numeric	2
Categorical	5
Boolean	0
Date	0
Text (Unique)	0
Rejected	2
Unsupported	0

Warnings

- `NumCaso` is highly correlated with `index` ($\rho = 1$) Rejected
- `IdentificacionRT-PCR_COVID19(tiemporeal)` has constant value confirmado Rejected
- `Llegada_México` has 281 / 33.1% missing values Missing

Variables

index

Numeric

Distinct count	848	Mean	423.5
Unique (%)	100.0%	Minimum	0
Missing (%)	0.0%	Maximum	847
Missing (n)	0	Zeros (%)	0.1%
Infinite (%)	0.0%		
Infinite (n)	0		



Tc

NumCaso

Highly correlated

This variable is highly correlated with `index` and should be ignored for analysis

Correlation 1

```
In [13]: AnalisisEstadisticoPromedioXGenero=df.groupby('Sexo').mean()
```

```
In [14]: AnalisisEstadisticoPromedioXGenero
```

```
Out[14]:
```

	index	NumCaso	Edad
Sexo			
F	446.986150	447.986150	41.958449
M	406.090349	407.090349	42.802875

```
In [15]: ColoresComponentesTabla=[[0,'#4d004c'],[.5,'#f2e5ff'],[1,'#ffffff']]
```

```
In [16]: ColoresLetra=['#000000']
```

```
In [17]: dz=ff.create_table(AnalisisEstadisticoPromedioXGenero,index=True,colorscale=ColoresComponentesTabla,font_colors=ColoresLetra)
         iplot(dz)
```

	index	NumCaso
F	446.9861495844875	447.9861495844875

Despliegue gráfico de resultados

```
In [18]: col="Sexo"
         AnalisisFrecuenciaXGenero=df[col].value_counts().reset_index()
```

```
In [19]: AnalisisFrecuenciaXGenero
```

```
Out[19]:
```

	index	Sexo
0	M	487
1	F	361

```
In [20]: AnalisisFrecuenciaXGenero=AnalisisFrecuenciaXGenero.rename(columns={col:"count", "index":col})
```

```
In [21]: AnalisisFrecuenciaXGenero
```


```
Out[21]:
```

	Sexo	count
0	M	487
1	F	361

Gráfica distribución registros X género

```
In [22]: trace=go.Pie(labels=AnalisisFrecuenciaXGenero[col],values=AnalisisFrecuenciaXGe  
nero['count'],pull=[0.05,0])  
layout={'title':'Género(Hombre, Mujer)'}  
fig=go.Figure(data=[trace],layout=layout)  
iplot(fig)
```


Género(Hombre, Mujer)



Distribución Edad


```
In [23]: plt.figure(figsize=(90,15))
plt.subplot(1,3,1)
sns.distplot(df["Edad"])
plt.title('Distribución Edad')

plt.show()
```



```
In [24]: x=df
```

```
In [25]: d1=x[x['Sexo']=='M']
```

```
In [26]: d1
```

Out[26]:

	index	NumCaso	Estado	Sexo	Edad	Fecha_de_Inicio_de_Sintomas	IdentificacionRT-PCR_COVID19(tiemporeal)	
	0	313	314	MÉXICO	M	44	2020-02-19	confirmado
	1	5	6	MÉXICO	M	71	2020-02-21	confirmado
	2	0	1	CDMX	M	35	2020-02-22	confirmado
	3	1	2	SINALOA	M	41	2020-02-22	confirmado
	4	2	3	CDMX	M	59	2020-02-23	confirmado

	841	741	742	SINALOA	M	43	2020-03-25	confirmado
	842	561	562	QUINTANA_ROO	M	75	2020-03-25	confirmado
	843	805	806	GUANAJUATO	M	30	2020-03-25	confirmado
	845	837	838	TABASCO	M	58	2020-03-26	confirmado
	846	845	846	MÉXICO	M	35	2020-03-26	confirmado

487 rows × 9 columns

```
In [27]: d2=x[x['Sexo']=='F']
```

```
In [28]: d2
```


Out[28]:

	index	NumCaso	Estado	Sexo	Edad	Fecha_de_Inicio_de_Sintomas	IdentificacionR1 PCR_COVID19(tiemporea)	
	5	4	5	CHIAPAS	F	18	2020-02-25	confirmad
	6	3	4	COAHUILA	F	20	2020-02-27	confirmad
	8	686	687	JALISCO	F	50	2020-03-01	confirmad
	9	32	33	JALISCO	F	64	2020-03-01	confirmad
	10	25	26	QUINTANA_ROO	F	71	2020-03-01	confirmad

	838	716	717	AGUASCALIENTES	F	5	2020-03-25	confirmad
	839	718	719	AGUASCALIENTES	F	37	2020-03-25	confirmad
	840	824	825	CDMX	F	35	2020-03-25	confirmad
	844	835	836	MÉXICO	F	73	2020-03-26	confirmad
	847	847	848	MÉXICO	F	61	2020-03-26	confirmad

361 rows × 9 columns

```
In [29]: x=df
col='Edad'
v1=x[col].value_counts().reset_index()
v1=v1.rename(columns={col:'count','index':col})
v1['percent']=v1['count'].apply(lambda x: 100 *x/sum(v1['count']))
v1=v1.sort_values(col)
trace1=go.Bar(x=v1[col],y=v1["count"],name="0",marker=dict(color="rgb(63, 72, 204)"))
y=[trace1]
layout={'title':"Distribución X Edad ", 'xaxis':{'title':"Edad"}, 'yaxis':{'title':"Frecuencia"}}
fig=go.Figure(data=y,layout=layout)
fig.layout.template='presentation'
iplot(fig)
```




```

In [30]: col='Edad'


v1=d1[col].value_counts().reset_index()
v1=v1.rename(columns={col:'count','index':col})
v1['percent']=v1['count'].apply(lambda x:100*x/sum(v1['count']))
v1=v1.sort_values(col)
v2=d2[col].value_counts().reset_index()
v2=v2.rename(columns={col:'count','index':col})
v2['percent']=v2['count'].apply(lambda x:100*x/sum(v2['count']))
v2=v2.sort_values(col)
tracel=go.Scatter(x = v1[col], y = v1["count"],name="Hombre",marker=dict(color="#ff7f0e"))
trace2= go.Scatter(x = v2[col],y = v2["count"], name = "Mujer", marker = dict(color="#a678de"))
y = [tracel, trace2]
layout={'title':"Comparación X Edad [[ Hombre vs Mujer ]] ", 'xaxis':{'title':"Edad"}, 'yaxis':{'title':"Frecuencia"}}
fig=go.Figure(data = y, layout = layout)
fig.layout.template='presentation'
iplot(fig)

```

Comparación X Edad [[Hombre vs Mu




```
In [31]: x=df
col='Estado'
v1=x[col].value_counts().reset_index()
v1=v1.rename(columns={col:'count','index':col})
v1['percent']=v1['count'].apply(lambda x: 100 *x/sum(v1['count']))
v1=v1.sort_values(col)
trace1=go.Bar(x=v1[col],y=v1["count"],name="0",marker=dict(color="#e377c2"))
y=[trace1]
layout={'title':"Distribución X Estado ", 'xaxis':{'title':''}, 'yaxis':{'title':
':"Frecuencia"}}
fig=go.Figure(data=y,layout=layout)
fig.layout.template='presentation'
iplot(fig)
```




In [32]: col='Estado'

```
v1=d1[col].value_counts().reset_index()
v1=v1.rename(columns={col:'count','index':col})
v1['percent']=v1['count'].apply(lambda x:100*x/sum(v1['count']))
v1=v1.sort_values(col)
v2=d2[col].value_counts().reset_index()
v2=v2.rename(columns={col:'count','index':col})
v2['percent']=v2['count'].apply(lambda x:100*x/sum(v2['count']))
v2=v2.sort_values(col)
trace1=go.Scatter(x = v1[col], y = v1["count"],name="Hombre",marker=dict(color="#d62728"))
trace2= go.Scatter(x = v2[col],y = v2["count"], name = "Mujer", marker = dict(color='rgb(63, 72, 204)'))
y = [trace1, trace2]
layout={'title':"Comparación X Estado [[ Hombre vs Mujer ]]", 'xaxis':{'title':"Estado"}, 'yaxis':{'title':"Frecuencia"}}
fig=go.Figure(data = y, layout = layout)
fig.layout.template='presentation'
iplot(fig)
```

Comparación X Estado [[Hombre vs M



```
In [33]: x = df
col='Procedencia'
v1=x[col].value_counts().reset_index()
v1=v1.rename(columns={col:'count','index':col})
v1['percent']=v1['count'].apply(lambda x: 100 *x/sum(v1['count']))
v1=v1.sort_values(col)
trace1=go.Bar(x=v1[col],y=v1["count"],name="0",marker=dict(color="#6ad49b"))
y=[trace1]
layout={'title':"Procedencia de la infección",'xaxis':{'title':"Procedencia"},'yaxis':{'title':"Frecuencia"}}
fig=go.Figure(data=y,layout=layout)
fig.layout.template='presentation'
iplot(fig)
```




```

In [34]: col='Procedencia'

v1=d1[col].value_counts().reset_index()
v1=v1.rename(columns={col:'count','index':col})
v1['percent']=v1['count'].apply(lambda x:100*x/sum(v1['count']))
v1=v1.sort_values(col)
v2=d2[col].value_counts().reset_index()
v2=v2.rename(columns={col:'count','index':col})
v2['percent']=v2['count'].apply(lambda x:100*x/sum(v2['count']))
v2=v2.sort_values(col)
trace1=go.Scatter(x = v1[col], y = v1["count"],name="Hombre",marker=dict(color="#17becf"))
trace2= go.Scatter(x = v2[col],y = v2["count"], name = "Mujer", marker = dict(color="#a678de"))
y = [trace1, trace2]
layout={'title':"Comparación X Procedencia [[ Hombre vs Mujer ]] ", 'xaxis':{'title':"Procedencia"}, 'yaxis':{'title':"Frecuencia"}}
fig=go.Figure(data = y, layout = layout)
fig.layout.template='presentation'
iplot(fig)

```

Comparación X Procedencia [[Hombre vs




Serie de tiempo: Casos por fecha

Casos de COVID19 de hombres en México por día


```
In [37]: casos_fecha_M = pd.DataFrame(d1['IdentificacionRT-PCR_COVID19(tiemporeal)'].groupby(d1['Fecha_de_Inicio_de_Síntomas']).count())
fig = go.Figure()
fig.add_trace(go.Scatter(
    x=casos_fecha_M.index,
    y=casos_fecha_M["IdentificacionRT-PCR_COVID19(tiemporeal)"],
    mode='lines+markers',
    name="Casos Nuevos Hombres",
    line_color='deepskyblue',
    opacity=0.8))

fig.add_trace(go.Scatter(
    x=casos_fecha_M.index,
    y=sc.cumsum(casos_fecha_M["IdentificacionRT-PCR_COVID19(tiemporeal)"]),
    mode='lines+markers',
    name="Casos Totales Hombres",
    line_color='#ff7f0e',
    opacity=0.8))
# Edit the layout
fig.update_layout(title='Casos de COVID19 de hombres en México por día',
    xaxis_title='Fecha',
    yaxis_title='Número de casos')
fig.show()
```

Casos de COVID19 de hombres en México por día




Casos de COVID19 de mujeres en México por día

```
In [38]: casos_fecha_F = pd.DataFrame(d2['IdentificacionRT-PCR_COVID19(tiemporeal)'].groupby(d2['Fecha_de_Inicio_de_Síntomas']).count())
fig = go.Figure()
fig.add_trace(go.Scatter(
    x=casos_fecha_F.index,
    y=casos_fecha_F["IdentificacionRT-PCR_COVID19(tiemporeal)"],
    mode='lines+markers',
    name="Casos Nuevos Mujeres",
    line_color='#a678de',
    opacity=0.8))

fig.add_trace(go.Scatter(
    x=casos_fecha_F.index,
    y=sc.cumsum(casos_fecha_F["IdentificacionRT-PCR_COVID19(tiemporeal)"]),
    mode='lines+markers',
    name="Casos Totales Mujeres",
    line_color='#ff7f0e',
    opacity=0.9))
# Edit the layout
fig.update_layout(title='Casos de COVID19 de Mujeres en México por día',
    xaxis_title='Fecha',
    yaxis_title='Número de casos')
fig.show()
```

Casos de COVID19 de Mujeres en México por día



Casos de COVID19 [Hombres vs Mujeres] en México por día

```
In [39]: casos_fecha_F = pd.DataFrame(d2['IdentificacionRT-PCR_COVID19(tiemporeal)'].groupby(d2['Fecha_de_Inicio_de_Síntomas']).count())
fig = go.Figure()


fig.add_trace(go.Scatter(
    x=casos_fecha_M.index,
    y=casos_fecha_M["IdentificacionRT-PCR_COVID19(tiemporeal)"],
    mode='lines+markers',
    name="Casos Nuevos Hombres",
    line_color='deepskyblue',
    opacity=0.8))

fig.add_trace(go.Scatter(
    x=casos_fecha_F.index,
    y=casos_fecha_F["IdentificacionRT-PCR_COVID19(tiemporeal)"],
    mode='lines+markers',
    name="Casos Nuevos Mujeres",
    line_color='#e377c2',
    opacity=0.8))

# Edit the layout
fig.update_layout(title='Casos de COVID19 [Hombres vs Mujeres] en México por día',
    xaxis_title='Fecha',
    yaxis_title='Número de casos')

fig.show()
```

Casos de COVID19 [Hombres vs Mujeres] en México por día



Casos de COVID19 en México por día

```
In [40]: casos_fecha = pd.DataFrame(df['IdentificacionRT-PCR_COVID19(tiemporeal)'].group
by(df['Fecha_de_Inicio_de_Síntomas']).count())
fig = go.Figure()
fig.add_trace(go.Scatter(
    x=casos_fecha.index,
    y=casos_fecha["IdentificacionRT-PCR_COVID19(tiemporeal)"],
    mode='lines+markers',
    name="Casos Nuevos",
    line_color='deepskyblue',
    opacity=0.8))

fig.add_trace(go.Scatter(
    x=casos_fecha.index,
    y=sc.cumsum(casos_fecha["IdentificacionRT-PCR_COVID19(tiemporea
l)"]),
    mode='lines+markers',
    name="Casos Totales",
    line_color='#ff7f0e',
    opacity=0.8))
# Edit the layout
fig.update_layout(title='Casos de COVID19 en México por día',
    xaxis_title='Fecha',
    yaxis_title='Número de casos')
fig.show()
```

Casos de COVID19 en México por día

